Universidad del Istmo de Guatemala · Facultad de Ingeniería

Contando clientes Buy 'Til You Die

BG/NBD desde cero: derivación, estimación, pronóstico y sus límites

Grupo 2 · Análisis y Ciencia de Datos · 29 de octubre de 2026

Agenda

1. El problema: clientes que se van sin avisar
2. El modelo pieza por pieza: supuestos y verosimilitud (Parte 1)
3. ¿Funciona el código? Simulación y ajuste a CDNOW (Partes 1 y 2)
4. Pronóstico de abajo hacia arriba contra arriba hacia abajo (Parte 3)
5. ¿Quién sigue vivo? El susto y la probabilidad correcta (Parte 4)
6. Cuando el modelo se rompe: Online Retail (Parte 5)
7. ¿Le gana una regresión logística? (Parte 6)
8. Lo que nos llevamos

El problema

Un contexto no contractual

Netflix sabe cuándo se va un cliente: cancela. Una tienda en línea **no**: quien compró en marzo y no ha vuelto puede estar de vacaciones, comprando en otro lado o perdido para siempre.

Las dos preguntas del gerente

1. ¿Cuántas compras van a hacer mis clientes en el próximo periodo?
2. ¿Cuáles de ellos siguen "vivos"?

La idea BTYD

Cada cliente compra como un proceso de Poisson mientras está activo y, en algún momento que no observamos, se "muere". Todo se responde con **tres números por cliente**: cuántas veces compró (x), cuándo fue la última (t_x) y cuánto tiempo lo hemos observado (T).

BTYD es una familia, no un modelo

El BG/NBD es una elección

Modelo	Compra	Muerte	Lo que cambia
NBD	Poisson, $\lambda \sim$ gamma	Nadie se muere	La base: mezcla gamma–Poisson
Pareto/NBD	Poisson, $\lambda \sim$ gamma	En cualquier momento	El original; verosimilitud incómoda
BG/NBD	Poisson, $\lambda \sim$ gamma	**Solo justo después de una compra**	Fácil de estimar
MBG/NBD	Poisson, $\lambda \sim$ gamma	También tras la primera compra	Con $x = 0$ ya puede estar muerto

La pieza que cambia todo

El BG/NBD solo permite morir **justo después de una compra repetida**. Eso vuelve la verosimilitud manejable (Fader, Hardie y Lee, 2005)… y es la que nos va a dar el susto de la Parte 4.

Los datos: CDNOW

Parte 0 – De 6,919 líneas a tres números por cliente

Clientes (primer trimestre de 1997)	2,357
Líneas originales	6,919
Transacciones cliente–día	6,696
Calibración: 1 ene – 30 sep 1997	39 semanas
Holdout: 1 oct 1997 – 30 jun 1998	39 semanas
Compras repetidas en calibración	2,457
Compras en el holdout	1,882

Por cliente (semanas = días/7)

- x: compras repetidas (la primera no cuenta)
- t_x: última compra, medida desde la primera
- T: de la primera compra al 30 de septiembre
- x^*: compras en el holdout

0.4

59.9 % de los clientes (1,411) no repitió en la calibración. T va de **27.0** a **38.9** semanas porque cada cliente llegó en una fecha distinta, pero la calibración termina el mismo día para todos.

El modelo pieza por pieza

Parte 1 – Los cinco supuestos que estamos firmando

1. Mientras está vivo, el cliente i compra según un proceso de Poisson con tasa λ_i.
2. Las tasas varían entre clientes: $\lambda \sim \text{Gamma}(r, \alpha)$, con media r/α.
3. Justo después de cada compra repetida, el cliente muere con probabilidad p_i.
4. Las probabilidades varían entre clientes: $p \sim \text{Beta}(a, b)$, con media $a/(a+b)$.
5. λ_i y p_i son independientes.

Ninguno es literalmente cierto

La pregunta no es si el modelo es verdadero, sino si es suficientemente bueno para la pregunta que le hacemos. Eso se comprueba: simulación (1.3), artículo (2.1) y holdout (Partes 3 y 4).

1.1 Un cliente con λ y p conocidas

Dos historias producen los mismos datos

Observamos x compras repetidas en $t_1 < \cdots < t_x$ y después nada hasta T.

A: sigue vivo en T

Compra en $t_1, \ldots, t_x$, sobrevive a cada compra y no compra en $(t_x, T]$. Los exponentes se telescopian:

$$\lambda e^{-\lambda t_1} \cdots \lambda e^{-\lambda(t_x - t_{x-1})}\, e^{-\lambda(T - t_x)} = \lambda^x e^{-\lambda T}$$

$$L_A = (1-p)^x \lambda^x e^{-\lambda T}$$

B: murió justo después de t_x

Sobrevive a $x-1$ compras y muere tras la última; el silencio posterior no requiere "no comprar":

$$L_B = p(1-p)^{x-1} \lambda^x e^{-\lambda t_x}$$

Si $x = 0$ **no existe**: sin compra repetida no hubo oportunidad de morir.

$$L(\lambda, p \mid x, t_x, T) = (1-p)^x \lambda^x e^{-\lambda T} + \delta_{x>0}\, p(1-p)^{x-1} \lambda^x e^{-\lambda t_x}$$

Los tiempos intermedios desaparecen: (x, t_x, T) son **estadísticos suficientes**.

1.2 La mezcla sobre λ y p

Gamma–Poisson para λ, función beta para p

Sobre λ (con $s = T$ o $s = t_x$)

$$\int_0^\infty \lambda^x e^{-\lambda s}\,\frac{\alpha^r \lambda^{r-1} e^{-\alpha\lambda}}{\Gamma(r)}\,d\lambda = \frac{\Gamma(r+x)\,\alpha^r}{\Gamma(r)\,(\alpha+s)^{r+x}}$$

(núcleo de una Gamma$(r+x, \alpha+s)$)

Sobre p

$$\int_0^1 (1-p)^x f(p)\,dp = \frac{B(a, b+x)}{B(a,b)} \qquad \int_0^1 p(1-p)^{x-1} f(p)\,dp = \frac{B(a+1, b+x-1)}{B(a,b)}$$

Resultado ($\lambda \perp p$: cada término se integra por separado)

$$L(r, \alpha, a, b \mid x, t_x, T) = \frac{\Gamma(r+x)\,\alpha^r}{\Gamma(r)}\left[\frac{B(a, b+x)}{B(a,b)}\frac{1}{(\alpha+T)^{r+x}} + \delta_{x>0}\frac{B(a+1, b+x-1)}{B(a,b)}\frac{1}{(\alpha+t_x)^{r+x}}\right]$$

De la fórmula al código

`src/bgnbd.py` y `src/ajuste_cdnow.py`

Log-verosimilitud estable

```
c = gammaln(r+x) - gammaln(r) + r*log(alpha)
A = betaln(a, b+x) - betaln(a, b) \
    - (r+x)*log(alpha+T)
B = betaln(a+1, b+x-1) - betaln(a, b) \
    - (r+x)*log(alpha+tx)
B = np.where(x > 0, B, -np.inf)
loglik = c + np.logaddexp(A, B)
```

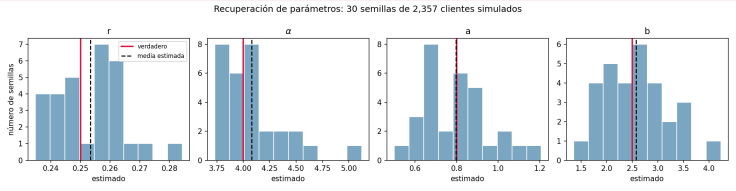
- `gammaln`/`betaln`: Γ directa se desborda.
- `logaddexp`: suma de dos términos sin desbordar.
- $x = 0$: el término B se fija en $-\infty$ (si $b < 1$, `betaln(a+1,b-1)` no tiene sentido).
- Optimizamos sobre $\log(r, \alpha, a, b)$ con L-BFGS-B, cotas ± 10 y cinco arranques.

Validamos antes de modelar

La fórmula cerrada coincide con la integral doble numérica (`dblquad`, error relativo $\sim 10^{-10}$), y con $x = 0$ da $(\alpha/(\alpha + T))^r$ para cualquier a, b.

1.3 Primero, datos que nosotros inventamos

2,357 clientes simulados, 30 semillas



	r	α	a	b
Verdadero	0.25	4.00	0.80	2.50
Media de 30 estimados	0.253	4.081	0.798	2.573
Coeficiente de variación	4.7 %	7.4 %	20.6 %	25.2 %

Sesgo menor al 3 % en los cuatro. La **compra** (r, α) se estima mucho mejor que la **muerte** (a, b): las compras se observan; la muerte solo se infiere de silencios largos, y el 60 % con $x = 0$ no informa nada sobre p.

2.1 Ajuste a CDNOW

Reproducimos el artículo original

	r	α	a	b	log-verosimilitud
Nuestro	0.2426	4.4136	0.7929	2.4259	-9582.43
Fader, Hardie y Lee (2005)	0.243	4.414	0.793	2.426	-9582.4

Qué confirma

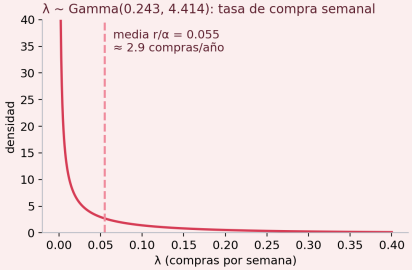
Que la verosimilitud está bien programada **y** que (x, t_x, T) está bien construido. Un error en cualquiera de los dos movería los estimados de forma visible.

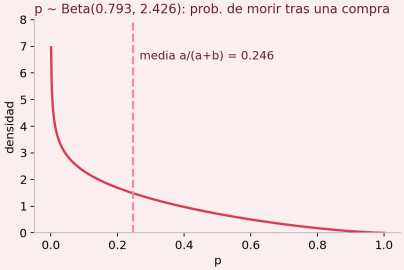
Cómo lo sabemos

Los cinco puntos iniciales llegan al mismo óptimo y ningún parámetro toca las cotas. Las diferencias en el cuarto decimal vienen del redondeo del artículo.

2.2 ¿Qué tan parecidos son los clientes?

Muy poco





$E[\lambda] = 0.055$ compras/semana para un cliente activo. Con $r < 1$ la moda está en cero: casi todos compran poco y unos pocos mucho (CV ≈ 2).

$E[p] = 0.246$: en promedio $\sim$4 compras antes de irse. Con $a < 1$ hay clientes casi inmortales junto a otros que se van rápido.

2.3 Bono: bootstrap sobre clientes

¿Qué tan precisos son los estimados reales?

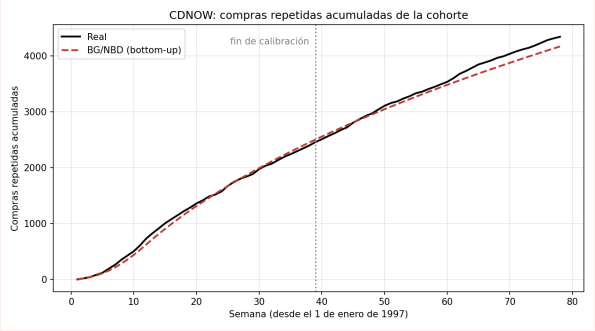
	r	α	a	b
Estimado CDNOW	0.243	4.414	0.793	2.426
Error estándar bootstrap (100 réplicas)	0.017	0.501	0.211	0.830
Desviación estándar en la simulación 1.3	0.012	0.300	0.164	0.649

Lectura

- Mismo orden que en la simulación: r es el más preciso, b el menos. La muerte es 3 a 5 veces más imprecisa que la compra.
- El bootstrap da dispersiones algo mayores: con datos reales, además del ruido muestral, aparece lo que el BG/NBD no describe bien.

3.1 Pronóstico bottom-up

Sumar los pronósticos de cada cliente, semana por semana



$$E[X(t)] = \frac{a+b-1}{a-1}\left[1 - \left(\frac{\alpha}{\alpha+t}\right)^r {}_2F_1(\cdot)\right]$$

donde ${}_2F_1(\cdot) = {}_2F_1\left(r, b; a+b-1; \frac{t}{\alpha+t}\right)$.

Curva de la cohorte: $\sum_i E[X(w - s_i)]$, con s_i la semana de llegada.

Holdout real	1,882
BG/NBD	1,664
Error	$-11.6\,\%$

En calibración la curva se encima con la real; en el holdout reproduce la forma, pero el modelo cree que la cohorte muere un poco más rápido de lo que murió.

3.2–3.3 Top-down contra bottom-up

Total pronosticado del holdout (real: 1,882)

Método	Total	Error	MAE semanal
BG/NBD (bottom-up)	**1,664**	**−11.6 %**	**9.83**
Promedio móvil, últimas 8 semanas	2,072	+10.1 %	11.67
Promedio móvil, últimas 4 semanas	2,126	+12.9 %	12.27
Tendencia lineal, semanas 28–39	2,306	+22.5 %	15.11
Media histórica	2,393	+27.2 %	16.09
Naive (semana 39)	2,418	+28.5 %	16.56
Tendencia lineal, semanas 1–39	2,626	+39.5 %	20.89

¿Quién gana?

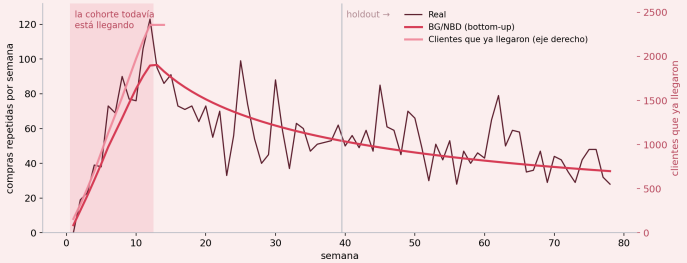
El BG/NBD en error semanal: es el único que sigue la caída. En el total, el promedio de 8 semanas queda cerca, pero todos los top-down sobreestiman.

Sensibilidad a la ventana

La tendencia cambia 320 compras según desde qué semana se ajuste. Nada en los datos dice cuál ventana escoger.

3.3 Las primeras 12 semanas

Lo que un método top-down no puede saber

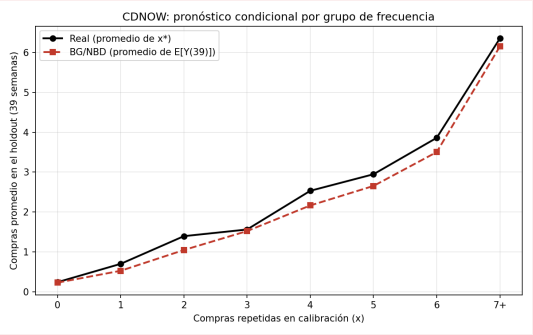


La cohorte todavía está llegando

Al final de la semana 1 habían llegado 157 clientes; hasta la semana 12 no están los 2,357. La serie sube porque **hay más clientes**, no porque compren más. Después baja porque se mueren. El top-down ve subida y bajada; el BG/NBD sabe la fecha de llegada de cada cliente.

3.4 Pronóstico por cliente

Lo que el top-down ni siquiera puede intentar

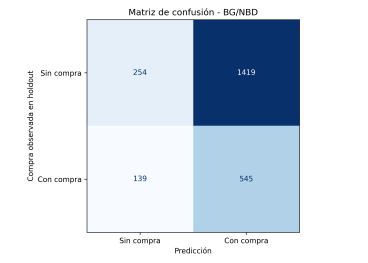


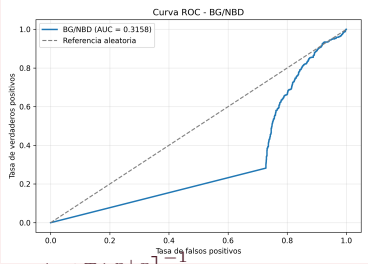
x	$E[Y(39)]$	Real x^*	Error
0	0.23	0.24	$-5\,\%$
1	0.52	0.70	$-25\,\%$
2	1.04	1.39	$-25\,\%$
3	1.52	1.56	$-3\,\%$
4	2.16	2.53	$-15\,\%$
5	2.65	2.95	$-10\,\%$
6	3.50	3.86	$-9\,\%$
7+	6.16	6.36	$-3\,\%$

Subestima en todos los grupos, sobre todo con 1 y 2 compras repetidas: el modelo cree que muchos murieron y volvieron. Aun así ordena perfecto de 0.2 a 6 compras. Un top-down solo ve el total: **no puede repartirlo entre clientes**.

4.1 ¿Quién sigue vivo?

$P(\text{vivo})$ como clasificador de quién compra en el holdout





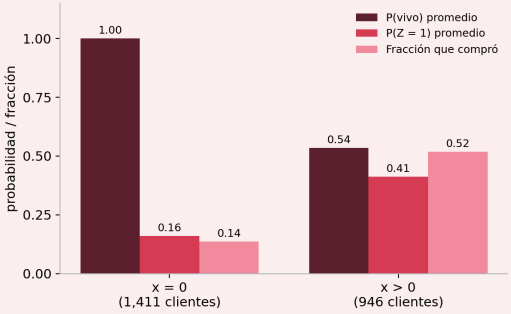
$$P(\text{vivo} \mid x, t_x, T) = \left[1 + \delta_{x>0} \frac{a}{b+x-1} \left(\frac{\alpha+T}{\alpha+t_x}\right)^{r+x}\right]^{-1}$$

El susto

Tasa base: **29.0 %**. Con umbral 0.5 la exactitud es 34 % y el **AUC es 0.316: peor que tirar una moneda**.

4.2 La explicación

Con $x = 0$, $P(\text{vivo}) = 1$



Por qué

En el BG/NBD solo se muere **después de una compra repetida**. Quien no repitió nunca tuvo la oportunidad: $\delta_{x>0} = 0$ y $P(\text{vivo}) = 1$.

La consecuencia

Esos 1,411 clientes (60 % de la base) reciben el puntaje más alto posible, pero solo el **13.7 %** compró. El ordenamiento se invierte. Solo con $x > 0$, el AUC sube a 0.698.

4.3 La probabilidad correcta

Estar vivo no es lo mismo que comprar

1. $P(Z=0) = P(\text{muerto}) \cdot 1 + P(\text{vivo}) \cdot P(\text{0 compras en } \tau \mid \text{vivo})$.
2. Un cliente vivo que no compra sigue vivo: no hay que modelar muertes durante τ.
3. Dado vivo, solo cuenta la historia A: $\lambda^x e^{-\lambda T} \times \text{Gamma}(r, \alpha) \Rightarrow$ $\lambda \mid \text{vivo} \sim \text{Gamma}(r+x, \alpha+T)$.
4. Mezcla gamma–Poisson: $P(0 \text{ en } \tau \mid \text{vivo}) = \int e^{-\lambda\tau}\, g(\lambda)\, d\lambda = \left(\frac{\alpha+T}{\alpha+T+\tau}\right)^{r+x}$.

Resultado

$$P(Z=1 \mid x, t_x, T) = P(\text{vivo} \mid x, t_x, T)\left[1 - \left(\frac{\alpha+T}{\alpha+T+\tau}\right)^{r+x}\right]$$

Con $x=0$ la tasa posterior es muy baja (≈ 0.006/semana): $P(Z=1) \approx 0.16$ aunque $P(\text{vivo}) = 1$. En promedio: $P(\text{vivo}) = 0.81$, $P(Z=1) = 0.26$, tasa real 0.29.

4.4 Verificación por simulación

20,000 clientes simulados con los parámetros estimados

Decil	1	2	3	4	5	6	7	8	9	10
Fórmula de 4.3	.120	.148	.153	.159	.164	.170	.182	.305	.448	.736
Fracción simulada	.123	.143	.148	.161	.187	.171	.182	.308	.429	.747

La fórmula es correcta

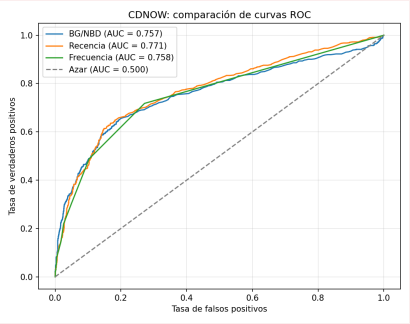
Las diferencias van de 0.000 a 0.023, del tamaño del ruido de simulación (con 2,000 clientes por decil, el error estándar es ≈ 0.01).

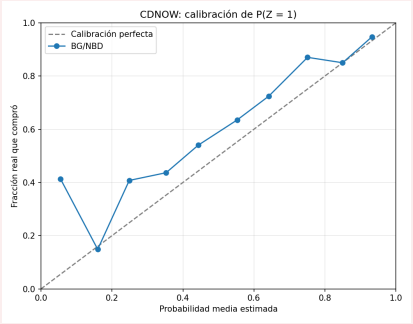
Pero ojo

Esto valida la **derivación**, no el modelo: los datos simulados cumplen el BG/NBD por construcción. Si el modelo describe a los clientes reales lo dice el siguiente paso.

4.5 Evaluación con los datos reales

Seamos honestos





	AUC
Recencia	.771
Frecuencia	.758
BG/NBD	.757
	Brier
BG/NBD	.161
Tasa base	.206

No ordena mejor que una variable

(x, t_x, T) son sus estadísticos suficientes: $P(Z = 1)$ es una forma de combinar recencia y frecuencia.

Lo que sí ofrece

Probabilidades con unidades (Brier 22 % mejor que la tasa base), cualquier horizonte y el total de la base.

4.6 Otro miembro de la familia: MBG/NBD

Se puede morir también después de la primera compra

	BG/NBD	MBG/NBD
log-verosimilitud	-9582.43	-9582.14
$P(\text{vivo})$ promedio con $x = 0$	1.000	0.409
AUC de $P(\text{vivo})$	0.316	0.687
AUC de $P(Z = 1)$	0.757	0.760
Total del holdout (real 1,882)	1,664 (-11.6 %)	1,572 (-16.5 %)

¿Por qué vale la fórmula de 4.3?

Solo usa que un vivo que no compra sigue vivo y que, dado vivo, $\lambda \sim \text{Gamma}(r + x, \alpha + T)$. El MBG/NBD conserva ambas; solo cambia $P(\text{vivo})$.

¿Con cuál mandamos la promoción?

Con $P(Z = 1)$, nunca con $P(\text{vivo})$. Ahí casi empatan (Spearman 0.98); preferimos el MBG/NBD por su supuesto más realista.

5.1 Online Retail: la muerte desaparece

2,959 clientes, calibración del 1 dic 2010 al 30 jun 2011

	r	α	a	b	$E[p]$	log-verosimilitud
CDNOW	0.243	4.414	0.793	2.426	0.246	$-9,582.4$
Online Retail, BG/NBD	0.739	9.199	**0.0002**	**264**	$\approx \mathbf{10^{-6}}$	$-15,181.7$
Online Retail, NBD (nadie muere)	0.739	9.201	–	–	0	$-15,181.7$

Qué pasó

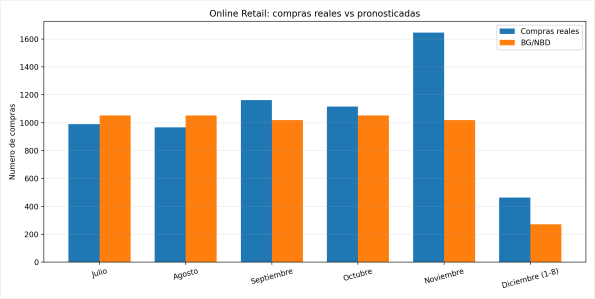
El modelo se volvió un NBD: misma verosimilitud. b no está identificado; lo que importa es $E[p] \approx 0$: no hay señal de abandono.

Por qué aquí y no en CDNOW

- Mayoristas que reabastecen con regularidad.
- No es una cohorte nueva: el 30 % ya compraba antes de diciembre de 2010.
- Calibración corta: $\sim$30 semanas.
- El 50 % de los $x = 0$ compró en el holdout (13.7 % en CDNOW).

5.2 El total del holdout y noviembre

Lo que ya sabíamos de la tarea de series de tiempo



	Real	BG/NBD	Error
Jul–oct	4,235	4,174	−1.4 %
Noviembre	1,646	1,018	−38.2 %
1–8 dic	463	271	−41.4 %
Total	6,344	5,463	−13.9 %

Un Poisson estacionario no ve la Navidad

Sin muerte, el pronóstico es una tasa constante que reparte las compras según los días del mes. Casi exacto de julio a octubre; todo el faltante está en el pico navideño, que la calibración (diciembre a junio) nunca vio.

6.1–6.2 ¿Le gana una regresión logística?

La comparación ingenua y por qué no fue justa

Logística de Z contra x, t_x, T; validación cruzada de 5 folds $\times$ 20 semillas.

	AUC	Brier
Logística	**0.779**	**0.156**
BG/NBD	0.757	0.161

Pesa más la **recencia** t_x (+), luego x (+); T entra con signo negativo.

Fuga de información

La logística aprendió con etiquetas de otros clientes **del holdout**: vio lo que pasó entre octubre de 1997 y junio de 1998. El BG/NBD nunca vio nada después del 30 de septiembre. El 30 de septiembre solo había etiquetas **anteriores**. Es la misma fuga de la tarea de series de tiempo: validar mezclando el futuro con el pasado.

6.3–6.4 La versión honesta y el cambio de horizonte

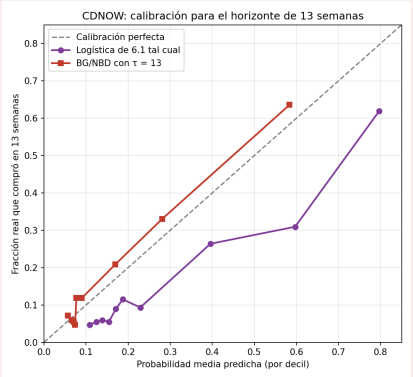
Predecir las primeras 13 semanas del holdout

Logística entrenada con cortes pasados (1 abr y 1 jul) y etiquetas de las 13 semanas siguientes:

13 semanas	AUC	Brier	Prob. media
Logística honesta	0.793	0.112	0.155
BG/NBD, $\tau = 13$	0.785	**0.110**	0.154
Tasa real			0.171

Le pedimos extrapolar

Entrenó con $T \in [1, 26]$ y se aplica con $T \in [27, 39]$: los rangos no se traslapan.



La logística de 6.1 usada tal cual a 13 semanas predice 0.29 cuando compró el 17 %: **ordena bien, estima mal**. Con el BG/NBD solo cambia τ.

6.5 Veredicto

Cada herramienta para su pregunta

Regresión logística

- Ordenar clientes para un horizonte fijo.
- Cuando hay etiquetas de un periodo anterior con ese mismo horizonte.
- Cuando se quieren agregar otras variables (monto, canal).

BG/NBD

- Cuando importan los niveles: probabilidades, compras esperadas.
- El total de la base (Parte 3), que la logística no responde.
- Cuando cambia el horizonte: solo cambia τ.
- Cuando no hay etiquetas previas: cohortes nuevas.

La lección de la Parte 6

La ventaja de la comparación ingenua venía de haber visto el futuro. En la versión honesta empatan en orden y el BG/NBD gana en calidad de las probabilidades.

Lo que nos llevamos

Sobre el método

1. **Validar antes de modelar**: integral numérica, simulación y artículo, antes de creerle a CDNOW.
2. **Tres números bastan**: (x, t_x, T) son estadísticos suficientes.
3. **Bottom-up**: sabe cuándo llegó cada cliente y reparte el pronóstico.

Sobre la interpretación

1. **Estar vivo no es comprar**: $P(\text{vivo})$ responde otra pregunta.
2. **Cada supuesto pesa en una conclusión**: muerte tras compra (Parte 4), estacionariedad (Parte 5).
3. **Una evaluación sin fuga** cambia el veredicto.

La moraleja del enunciado

El BG/NBD no es “el” modelo: es una elección. Nuestro trabajo fue decir qué supuesto de esa elección pesa en cada conclusión.

Reproducibilidad

Todo corre a partir de los archivos originales

Repositorio

`github.com/Dnatam/Proyecto2-AnalisisDeDatos-G2`

- `src/`: un script por inciso; `bgnbd.py` y `mbgnbd.py` contienen los modelos.
- `documentos/`: derivaciones y respuestas por parte.
- `resultados/`: todas las tablas y gráficas de esta presentación.

Datos y referencias

CDNOW (B. Hardie, brucehardie.com/datasets) · Online Retail (UCI Machine Learning Repository) · Fader, Hardie y Lee (2005), *Marketing Science* 24(2) · Batislam, Denizel y Filiztekin (2007), *IJRM* 24(3) · Hyndman y Athanasopoulos, *FPP2*, §10.3–10.4.

¡Gracias! ¿Preguntas?