Propuesta de proyecto 2 (actualizada)

Contando clientes con modelos Buy 'Til You Die

Análisis y Ciencia de Datos

Sofía Blanco – Katherine Diéguez – Daniela Natareno

Versión final: 29 de octubre de 2026

Objetivo y organización del equipo

El proyecto implementa y evalúa modelos probabilísticos de comportamiento de compra, principalmente BG/NBD y MBG/NBD, con datos de CDNOW y Online Retail. Incluye derivaciones matemáticas, estimación de parámetros, simulaciones, pronósticos y evaluaciones de desempeño, además de los apartados opcionales de bootstrap (2.3) y regresión logística (Parte 6). Todo quedó implementado en el repositorio `github.com/Dnatam/Proyecto2-AnalisisDeDatos-G2`.

La distribución final de responsabilidades fue la siguiente:

Katherine Diéguez: preparación de CDNOW (0.1–0.4); derivación matemática de la verosimilitud (1.1–1.2) y su verificación numérica; implementación del BG/NBD (`bgnbd.py`) y ajuste de parámetros con comparación contra el artículo (2.1); pronóstico bottom-up (3.1) y por cliente (3.4); probabilidad de compra $P(Z = 1)$ (4.3); implementación, ajuste y comparación del MBG/NBD (4.6); cambio de horizonte de la logística (6.4); diagnóstico NBD de Online Retail (5.1); y redacción de las respuestas por parte.

Sofía Blanco: diseño y ejecución de la simulación con 30 semillas y recuperación de parámetros (1.3); bootstrap sobre clientes (2.3); pronósticos agregados top-down y tabla comparativa (3.2–3.3); validación por simulación de $P(Z = 1)$ (4.4); comparación del holdout de Online Retail (5.2); y evaluación con regresión logística: validación cruzada (6.1) y comparación temporal (6.3).

Daniela Natareno: organización del repositorio y documentación; pruebas del estimador y validación del optimizador; interpretación y visualización de parámetros (2.2); interpretación de pronósticos; evaluación de $P(\text{vivo})$ y $P(Z = 1)$ como clasificadores (4.1, 4.2 y 4.5); limpieza, preparación y ajuste de Online Retail, con el análisis mensual (5.1–5.2); y documentación de la fuga de información y de la conclusión de la Parte 6 (6.2, 6.5).

Las tres integrantes participaron en la revisión de resultados, la elaboración de conclusiones y la presentación final, que se reparte en tres bloques: Partes 0–1, Partes 2–4.3 y Partes 4.4–6.

Plan de simulación (inciso 1.3)

Se simularon 2,357 clientes con los parámetros poblacionales $r = 0.25$, $\alpha = 4$, $a = 0.8$ y $b = 2.5$. Para cada cliente se generó una tasa de compra a partir de una distribución Gamma y una probabilidad de abandono a partir de una distribución Beta; después se simularon las compras (tiempos exponenciales) y el abandono (después de cada compra repetida) bajo los supuestos del BG/NBD, con periodos de observación T entre 27 y 39 semanas.

El experimento se repitió con 30 semillas. En cada repetición se estimaron los cuatro parámetros por máxima verosimilitud con nuestra implementación en Python (`gammaln`, `betaln`, `logaddexp`) y optimización con `scipy.optimize.minimize` (L-BFGS-B sobre los logaritmos de los parámetros, varios puntos iniciales).

El criterio de éxito era recuperar parámetros cercanos a los verdaderos, con convergencia consistente y sin errores sistemáticos. **Resultado:** el criterio se cumplió.

	r	α	a	b
Valor verdadero	0.25	4.00	0.80	2.50
Media de 30 estimados	0.253	4.081	0.798	2.573
Desviación estándar	0.012	0.300	0.164	0.649
Sesgo relativo	+1.3 %	+2.0 %	−0.3 %	+2.9 %

Los parámetros de la compra (r, α) se estiman con más precisión que los de la muerte (a, b), porque la muerte nunca se observa directamente. Con el código validado, el ajuste a CDNOW reprodujo el artículo original: $r = 0.243$, $\alpha = 4.414$, $a = 0.793$, $b = 2.426$ y log-verosimilitud -9582.4.

Entregables

- **Repositorio de GitHub:** código reproducible a partir de los archivos originales (un script por inciso en `src/`), datos preparados, tablas y gráficas en `resultados/`, y `README.md` con el orden de ejecución y la ubicación de cada inciso.
- **Documentación:** derivaciones de 1.1, 1.2 y 4.3, simulaciones, estimaciones, comparaciones y respuestas por parte en `documentos/`.
- **Presentación:** diapositivas en PDF en `presentacion/`, de 20 a 25 minutos, con la participación de las tres integrantes.